



**HỌC VIỆN
NGÂN HÀNG**
BANKING ACADEMY OF VIETNAM

IS54A - Trí tuệ nhân tạo

Chương 6 – Thị giác máy tính



6.1. Tổng quan về dữ liệu hình ảnh và Thị giác máy tính

6.2. Các bài toán chính trong Thị giác máy tính


6.3. Các hướng tiếp cận bài toán Thị giác máy tính

6.4. Mạng CNN và các biến thể cho CV


6.1. Tổng quan về dữ liệu hình ảnh và Thị giác máy tính



Human Vision System



Computer Vision System





- **Khái niệm:** Thị giác máy tính (CV – Computer Vision) là lĩnh vực thuộc AI giúp máy tính có khả năng "nhìn" và hiểu nội dung hình ảnh/video như con người.
- **Mục tiêu cốt lõi:** Chuyển đổi dữ liệu phi cấu trúc (pixels) thành thông tin có cấu trúc (labels, bounding boxes, masks)
- **Sự khác biệt:**
 - *Xử lý ảnh (Image Processing):* input là ảnh, output là ảnh (ví dụ: làm nét, lọc nhiễu)
 - *Thị giác máy tính (CV):* input là ảnh, output là tri thức/quyết định (ví dụ: nhận diện hành vi).



- **Điểm ảnh (Pixel):** Đơn vị nhỏ nhất của hình ảnh kỹ thuật số
- **Cấu trúc ma trận:** Một bức ảnh thực chất là một ma trận 2D (ảnh xám) hoặc 3D (ảnh màu) chứa các giá trị màu sắc RGB


Độ phân giải (Resolution):
Số lượng pixel theo chiều ngang và dọc



157	153	174	168	150	152	129	151	172	161	155	156
165	182	163	74	75	62	39	17	110	210	180	154
180	180	50	14	34	6	10	33	48	106	159	181
206	109	5	124	131	111	120	204	166	15	56	180
194	68	137	251	237	239	239	228	227	87	71	201
172	106	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	106	95	190
205	174	165	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	85	150	79	38	218	241
190	224	147	108	227	210	127	102	36	101	255	224
190	214	173	66	103	143	96	80	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	143	0	0	12	108	200	136	243	236
195	206	123	207	177	121	123	200	175	13	96	218




- **Grayscale (Ảnh xám):** Mỗi pixel gồm 1 kênh giá trị duy nhất từ **0** (Đen) đến **255** (Trắng)
- **RGB (Ảnh màu):** Kết hợp từ 3 kênh màu: **Red, Green, Blue**. Mỗi pixel là một vector $[R, G, B]$





Một bức ảnh màu kích thước 28 x 28 thực chất là một Tensor có shape là (28, 28, 3) tương đương 784 input

Mỗi input có thể coi như một features?






TẠI SAO THỊ GIÁC MÁY TÍNH LẠI KHÓ?


NHỮNG THÁCH THỨC CỐT LỖI (CORE CHALLENGES)

THAY ĐỔI GÓC NHÌN (Viewpoint Variation)



Vật thể nhìn từ các hướng khác nhau tạo ra ma trận pixel hoàn toàn khác nhau.

ĐIỀU KIỆN ÁNH SÁNG (Illumination)



Cùng một khuôn mặt ở điều kiện ánh sáng khác nhau làm khó việc trích xuất đặc trưng.


BIẾN DẠNG (Deformation)



Vật thể mềm thay đổi hình dáng nhưng vẫn là cùng một đối tượng.

THÁCH THỨC BỐI CẢNH (CONTEXTUAL CHALLENGES)

CHE KHUẤT (Occlusion)



Vật thể bị che mất một phần
(ví dụ: xe hơi bị khuất sau cái cây).

NHIỀU NỀN (Background Clutter)



Vật thể có màu sắc hoặc cấu trúc
tương đồng với môi trường xung
quanh (ngụy trang).

ĐA DẠNG NỘI TẠI (Intra-class Variation)



"Cái ghế" có hàng nghìn kiểu dáng,
màu sắc khác nhau nhưng AI phải
học được đặc trưng chung của "ghế".



- **Tài chính - Ngân hàng:** Nhận diện khuôn mặt (eKYC), đọc ký tự trên hóa đơn/hợp đồng (OCR)
- **An ninh:** Phát hiện hành vi bất thường, giám sát giao thông
- **Y tế:** Chẩn đoán bệnh qua ảnh X-quang, MRI.
- **Sản xuất:** Kiểm tra lỗi sản phẩm trên dây chuyền tự động.



6.1. Tổng quan về dữ liệu hình ảnh và Thị giác máy tính

6.2. Các bài toán chính trong Thị giác máy tính


6.3. Các hướng tiếp cận bài toán Thị giác máy tính

6.4. Mạng CNN và các biến thể cho CV



Core Computer Vision Tasks

Recognition




Identify what it is

Segmentation




Divide into parts

Detection




Classification




Sort into categories

Retrieval




Find & return similar

Generation / Transformation



Create or modify

6.2. Các bài toán chính trong Thị giác máy tính



Tìm một số bộ dataset phổ biến cho mỗi bài toán (1) – (5) này



- **Định nghĩa:** Gán một nhãn (label) duy nhất cho toàn bộ bức ảnh. Trả lời câu hỏi: "Đối tượng chính trong ảnh này là gì?"
- **Đặc điểm:** Không quan tâm đến vị trí hay số lượng vật thể. Chỉ quan tâm đến xác suất cao nhất của một lớp (class)
- **Ví dụ:** Hệ thống phân loại ảnh X-quang là "Bình thường" hay "Viêm phổi"

- **Định nghĩa:** Không chỉ cho biết ảnh có gì mà còn chỉ ra vị trí của đối tượng đó bằng một khung hình chữ nhật (**Bounding Box**)
- **Đầu ra (Output):** Bao gồm nhãn lớp (Class) và tọa độ (x, y, w, h) của box
- **Ứng dụng:** Thường dùng khi trong ảnh chỉ có một đối tượng chính cần quan tâm đặc biệt (ví dụ: định vị khối u trong ảnh y tế)




- **Định nghĩa:** Xác định vị trí và phân loại **nhiều vật thể** thuộc các lớp khác nhau trong cùng một khung hình.
- **Thử thách:** Phải xử lý được sự chồng lấn giữa các vật thể và biến động về kích thước (Scalability).
- **Thuật toán tiêu biểu:** YOLO (You Only Look Once), SSD, Faster R-CNN.
- **Ví dụ:** Camera giao thông đếm số lượng xe máy, ô tô và người đi bộ tại ngã tư.

So far, we know some evaluation metrics:



- MAE, MSE for regression tasks
- Accuracy, Precision, Recall, F1-score for classification tasks
- BLEU, ROUGH for some NLP tasks

How to evaluate an object detection model?





<https://www.v7labs.com/blog/intersection-over-union-guide>





Mathematically


$$\text{Intersection over Union } (IoU) = \frac{|A \cap B|}{|A \cup B|}$$

But for binary classification, it is written as:


$$\text{Intersection over Union } (IoU) = \frac{TP}{TP + FN + FP}$$

- TP= True Positive.
- FN= False Negative
- FP= False Positive

Object detection evaluation - Exercise



$$y = (p_c, b_x, b_y, b_h, b_w, c)$$



```
ground_truth = [
    (50, 50, 40, 60),
    (30, 30, 20, 20),
    (70, 80, 30, 40)
]
```

```
model_a_preds = [
    (48, 52, 42, 58),
    (32, 31, 18, 19),
    (69, 79, 31, 41)
]
```

```
model_b_preds = [
    (45, 55, 30, 50),
    (28, 30, 22, 20),
    (75, 85, 28, 38)
]
```



- **Định nghĩa:** Phân loại từng điểm ảnh (**pixel-level**) vào một lớp cụ thể. Trả lời câu hỏi: "Pixel này thuộc về thực thể nào?".
- **Đặc điểm:** Không phân biệt các cá thể trong cùng một lớp. Ví dụ: 5 con chó đứng cạnh nhau sẽ được tô cùng một màu (lớp "Chó").
- **Ứng dụng:** Xe tự lái nhận diện đâu là vùng "đường đi", đâu là "vĩa hè".






- **Định nghĩa:** Kết hợp giữa Object Detection và Semantic Segmentation.
- **Đặc điểm:** Không chỉ phân loại pixel theo lớp mà còn tách biệt từng cá thể riêng lẻ. Ví dụ: Mỗi con chó trong 5 con chó sẽ được tô một màu khác nhau.
- **Thuật toán tiêu biểu:** Mask R-CNN.
- **Ví dụ:** Đếm chính xác số lượng tế bào trong ảnh vi sinh và xác định ranh giới của từng tế bào.



- **Định nghĩa:** Xác định vị trí của các điểm mẫu chốt cấu thành nên cấu trúc của vật thể.
- **Ứng dụng phổ biến nhất: Human Pose Estimation** (Ước lượng dáng người) bằng cách tìm các khớp vai, khuỷu tay, đầu gối.



Đâu là bài toán đơn giản / phức tạp nhất?





- **Định nghĩa:** Chuyển đổi dữ liệu hình ảnh chứa văn bản (viết tay hoặc in) sang định dạng văn bản máy tính có thể chỉnh sửa.
- **Các bước chính:** Phát hiện vùng chứa văn bản (Text Detection) và Nhận dạng ký tự (Text Recognition).
- **Ứng dụng:** Tự động hóa nhập liệu hóa đơn, đọc biển số xe (ALPR), số hóa tài liệu lưu trữ của ngân hàng.



- **Định nghĩa:** Hiểu sự thay đổi của vật thể qua các khung hình liên tiếp (Temporal dimension).
- **Yếu tố then chốt:** Sự kết hợp giữa đặc trưng không gian (Spatial) từ CNN và đặc trưng thời gian (Temporal) từ RNN/LSTM hoặc 3D-CNN.
- **Ví dụ:** Phân biệt hành động "đặt túi xách xuống" và "bỏ chạy" trong an ninh công cộng.



6.1. Tổng quan về dữ liệu hình ảnh và Thị giác máy tính

6.2. Các bài toán chính trong Thị giác máy tính

6.3. Các hướng tiếp cận bài toán Thị giác máy tính

6.4. Mạng CNN và các biến thể cho CV



- **Thị giác máy tính truyền thống (Traditional/Classical CV):** Dựa trên các thuật toán toán học và xử lý tín hiệu số để trích xuất đặc trưng thủ công.
- **Thị giác máy tính hiện đại (Deep Learning-based CV):** Sử dụng các mạng thần kinh nhân tạo sâu để tự động học các đặc trưng từ dữ liệu thô.
→ Từ "Feature Engineering" (Kỹ nghệ đặc trưng) sang "Feature Learning" (Học đặc trưng)



- **Khái niệm:** Các chuyên gia xác định các đặc trưng quan trọng (cạnh, góc, màu sắc) và viết thuật toán để trích xuất chúng.
- **Quy trình:** Ảnh đầu vào -> Trích xuất đặc trưng (SIFT, HOG) -> Thuật toán phân loại (SVM, Random Forest) -> Kết quả





- **SIFT (Scale-Invariant Feature Transform):** Tìm các điểm đặc trưng không thay đổi khi vật thể bị xoay, phóng to hay thu nhỏ.
- **HOG (Histogram of Oriented Gradients):** Tập trung vào cấu hình hình học và hướng của các cạnh.
- **Ứng dụng:** Rất mạnh trong việc so khớp ảnh (image stitching) hoặc nhận diện vật thể đơn giản.



- **Haar Cascades:** Sử dụng các bộ lọc hình chữ nhật đơn giản để phát hiện sự thay đổi cường độ sáng
- **Ưu điểm:** Tốc độ cực nhanh, có thể chạy trên các phần cứng có cấu hình rất yếu.
- **Hạn chế:**
 - **Tính mong manh (Fragility):** Dễ thất bại khi điều kiện ánh sáng, góc nhìn hoặc bối cảnh thay đổi
 - **Thiếu tính tổng quát:** Một bộ trích xuất đặc trưng được thiết kế cho "xe hơi" khó có thể dùng tốt cho "tế bào y tế"
 - **Giới hạn của con người:** Con người khó có thể định nghĩa hết các đặc trưng phức tạp trong các bức ảnh tự nhiên



- **Khái niệm:** Mô hình nhận vào ảnh thô và trả ra kết quả cuối cùng. Các tầng trong mạng thần kinh sẽ tự đảm nhiệm việc tìm ra đặc trưng nào là quan trọng nhất.





- **Các tầng thấp (Lower layers):** Học các đặc trưng cơ bản như cạnh (edges), nét gạch, màu sắc đơn nhất.
- **Các tầng giữa (Middle layers):** Kết hợp các cạnh thành các hình khối, họa tiết (textures, shapes)
- **Các tầng cao (Higher layers):** Kết hợp các hình khối thành các bộ phận vật thể (mắt, mũi, bánh xe) và đối tượng hoàn chỉnh



- **Hiệu suất vượt trội:** Kể từ cuộc cách mạng AlexNet (2012), độ chính xác của Deep Learning đã bỏ xa các phương pháp truyền thống
- **Tính bền vững (Robustness):** Chịu được nhiễu, che khuất và biến đổi góc nhìn tốt hơn nhờ học từ hàng triệu ví dụ
- **Tính linh hoạt:** Một kiến trúc mạng (như ResNet) có thể áp dụng cho nhiều miền dữ liệu khác nhau chỉ bằng cách thay đổi dữ liệu huấn luyện




<https://www.kaggle.com/datasets/zalando-research/fashionmnist>

Fashion clothes classification

Input: a 28x28 image in grayscale

Output: which kind of clothes:

- 0 T-shirt/top
- 1 Trouser
- 2 Pullover
- 3 Dress
- 4 Coat
- 5 Sandal
- 6 Shirt
- 7 Sneaker
- 8 Bag
- 9 Ankle boot





<https://www.kaggle.com/code/hatomugi/svm-with-0-9-accuracy>

Build a handwritten digit recognition model with SVM

Tải mã nguồn đi kèm bài 12 trên Google Drive, thực hành theo kịch bản cho trước trong file .ipynb

Xây dựng lại mô hình SVM phân loại ảnh với trích xuất đặc trưng theo kiểu HOG

Nộp lại notebook trên classroom và giải thích (cộng 1 contribution cho 3 bạn đầu tiên nộp và có giải thích)



- **Face Detection using Cascade Classifier using OpenCV - Python**

- Phát hiện khuôn mặt dựa vào đặc trưng Haar Cascade (Pretrained)
- Thử nghiệm với ảnh tự upload và nhận xét kết quả

<https://www.geeksforgeeks.org/python/face-detection-using-cascade-classifier-using-opencv-python/>



6.1. Tổng quan về dữ liệu hình ảnh và Thị giác máy tính


6.2. Các bài toán chính trong Thị giác máy tính

6.3. Các hướng tiếp cận bài toán Thị giác máy tính

6.4. Mạng CNN và các biến thể cho CV



- **Vấn đề về tham số:** Một ảnh màu **224x224 ~ 150k** input. Nếu tầng ẩn có 1000 neurons, mạng MLP cần **150 triệu tham số** chỉ cho tầng đầu tiên → Quá tải tính toán, dễ Overfitting.
 - **Mất cấu trúc không gian:** MLP "làm phẳng" (flatten) ảnh thành vector, làm mất đi mối liên hệ giữa các pixel cạnh nhau.
- CNN Sử dụng kết nối cục bộ (Local Connectivity) và chia sẻ trọng số (Weight Sharing)






- **Cơ chế:** Một bộ lọc (Kernel/Filter) trượt trên ảnh để thực hiện phép nhân vô hướng từng phần.
- **Vai trò:** Trích xuất các đặc trưng như cạnh, góc, họa tiết
- Tham số quan trọng:

Kernel Size: Kích thước bộ lọc



Stride: Bước nhảy của bộ lọc.

Padding: Thêm viền (thường là số 0) để giữ nguyên kích thước ảnh sau tích chập.






- **Cơ chế:** Down-sampling để giảm kích thước không gian của bản đồ đặc trưng (Feature Map)
 - **Max Pooling:** Lấy giá trị lớn nhất trong cửa sổ (giữ lại đặc trưng mạnh nhất)
 - **Average Pooling:** Lấy giá trị trung bình
- **Lợi ích:** Giảm khối lượng tính toán và giúp mô hình "bất biến" hơn với những dịch chuyển nhỏ của vật thể





- **Fully Connected (FC) Layer:** Nằm ở cuối mạng, tổng hợp tất cả các đặc trưng đã học được để đưa ra quyết định phân loại cuối cùng (thường kết hợp với hàm **Softmax**)







Kiến trúc	Đặc điểm đột phá	Ưu điểm	Nhược điểm	Ứng dụng phù hợp
VGGNet	Đồng nhất bộ lọc 3x3	Kiến trúc đơn giản, dễ hiểu, dễ cài đặt.	Rất nặng, tiêu tốn nhiều bộ nhớ và tham số.	Bài toán đơn giản, Transfer Learning cơ bản.
ResNet	Skip Connection (Phần dư)	Giải quyết triệt tiêu Gradient, mạng cực sâu.	Độ phức tạp tính toán tăng dần theo số tầng.	Hầu hết các bài toán CV hiện đại (Base model).
Inception	Multi-scale (Nhiều size filter)	Hiệu quả tham số cao, trích xuất đa đặc trưng.	Kiến trúc phức tạp, khó tùy chỉnh/mở rộng.	Nghiên cứu sâu về trích xuất đặc trưng đa dạng.
MobileNet	Depthwise Separable Conv	Cực nhẹ, tốc độ xử lý nhanh.	Độ chính xác thấp hơn một chút so với ResNet.	Thiết bị di động, IoT, Camera thời gian thực.
EfficientNet	Compound Scaling	Cân bằng tối ưu giữa Depth, Width & Resolution.	Yêu cầu kỹ thuật huấn luyện và tài nguyên GPU tốt.	Khi cần độ chính xác SOTA với tài nguyên vừa phải.



- Cho bài đọc tại <https://stanford.edu/~shervine/teaching/cs-230/cheatsheet-convolutional-neural-networks/>
 - Nếu chúng ta có một ảnh đầu vào kích thước $32 \times 32 \times 3$, thực hiện tích chập với 10 bộ lọc 5×5 , $s=1$, $p=0$ thì kích thước Output đầu ra là bao nhiêu?
 - Tính số lượng tham số cần học cho lớp Max Pooling với pooling size = 2×2



Xây dựng CNN Baseline

- Sử dụng dataset CIFAR-10.
- Tự thiết kế một kiến trúc CNN đơn giản (3-4 layer Conv).
- **Yêu cầu:**
 - Vẽ đồ thị Loss/Accuracy và Confusion Matrix.
 - So sánh thời gian huấn luyện và inference giữa việc sử dụng CPU và GPU (trên môi trường Google Colab)



Transfer Learning với ResNet50

- Vẫn sử dụng CIFAR-10 hoặc sử dụng một tập dữ liệu thực tế hơn (ví dụ: Phân loại các loại phương tiện giao thông hoặc khẩu trang).
- Thực hành kỹ thuật Fine-tuning và Feature Extraction (đóng băng layers).
- So sánh thời gian huấn luyện và inference giữa việc sử dụng CPU và GPU (trên môi trường Google Colab)